

SEMINARIOS

Propuesta de Contenidos

Aplicaciones Avanzadas de la IA
Máster en Ingeniería Informática (2025/26)

Grupo 1:

Alejandro Iabín Arteaga Hernández

Yulicenia Díaz Cabrera

Emanuel Pacheco Rojas

Víctor Ramos Osuna

David Reyes Alés

Aldair Verdugo Valerio

Título

IA Neurosimbólica en Grandes Modelos de Lenguaje: Arquitecturas Híbridas, Solucionadores y el Problema del "Symbol Grounding"

Resumen

Esta wiki se ubicará dentro de la categoría Trabajo Técnico y Survey (Revisión de Área), de acuerdo a las directrices de la guía de seminarios. El documento se dedicará a hacer un análisis exhaustivo de la incorporación de la Inteligencia Artificial Neurosimbólica (NeSy) a los Grandes Modelos de Lenguaje (LLM). En conjunto, la wiki explorará cómo la naturaleza probabilística de los LLMs (propensa a alucinaciones e inconsistencias lógicas) se combina con la verificabilidad determinista y matemática de los motores de inferencia simbólica.

El núcleo del trabajo será diseccionar los pipelines algorítmicos exactos de implementaciones del estado del arte (Logic-LM, LLM+P, DUPLEX, AlphaGeometry2), explicando paso a paso el flujo de información: desde la ingesta en lenguaje natural, a su extracción a esquemas estructurados (JSON/PDDL) o lógicos (SAT/SMT), el procesamiento por solvers externos, y la implementación de bucles de

retroalimentación de errores (Self-Refinement). Por último, la wiki se mantendrá en una posición estrictamente crítica respecto al estado de esta tecnología, evaluando la latencia, el alto coste computacional y la extrema fragilidad de la interfaz de traducción neurosimbólica.

Índice (Inicial, sujeto a cambio)

1. Introducción a la IA Neurosimbólica (NeSy) y el Paradigma de los LLM

1.1. El Problema del “Symbol Grounding” y la Naturaleza del Razonamiento: Análisis de la dicotomía histórica entre el aprendizaje inductivo/estadístico (LLMs) y el razonamiento deductivo/simbólico.

1.2. Taxonomía de Integración de NeSy: Clasificación estándar adaptada a LLMs con base en modelo de Kautz (Tipos 1 a 6). Básica diferencia técnica entre:

- Integración en la Formación: Utilizar funciones de pérdida (por ejemplo, Semantic Loss) que penalicen las contradicciones lógicas con el fin de incorporar el conocimiento simbólico en los pesos de la red neuronal.
- Integración en tiempo de inferencia: Orquestación de LLMs que interactúan dinámicamente con herramientas lógicas y solvers externos.

2. Restricciones Estructurales de los LLMs y el Rescate Simbólico

2.1 . Fallas estructurales de los modelos conexionistas: Evaluación técnica de las alucinaciones, opacidad, falta de interpretabilidad y debilidad crítica en el razonamiento multi-paso, deducción formal, y problemas de generalización composicional.

2.2. Ventajas de la arquitectura simbólica: El papel que desempeñan los planificadores clásicos y motores de razonamiento algoritmo para proporcionar garantías de seguridad verificables matemáticamente, búsqueda de rutas óptimas y un comportamiento de ejecución completamente determinista.

3. Casos de Uso y Pipelines Algorítmicos de Modelos NeSy-LLM

3.1. Planificación Robótica y Extracción de Información (DUPLEX y LLM+P):

Pipeline: El LLM no actúa como generador de planes end-to-end ni como generador de código, sino estrictamente como un Extractor de Información (IE) guiado por esquemas. Recibe lenguaje natural y extrae objetos/relaciones a formatos estructurados que un mapeador determinista traduce al lenguaje PDDL (Planning Domain Definition Language)..

Ejecución: Un planificador clásico (ej. Fast Downward) computa el problema PDDL. Si tiene éxito, devuelve un plan que el LLM traduce de vuelta a lenguaje natural.

3.2. Solucionadores SAT/SMT y Lógica de Primer Orden (Logic-LM y CEGIS):

Pipeline: Formulación del problema donde el LLM traduce lenguaje natural a representaciones simbólicas formales (First-Order Logic, Python restrictivo) mediante aprendizaje en contexto.

Bucle de Reflexión (Self-Refinement): Si el motor de inferencia deductiva (ej. Z3) encuentra contradicciones o errores de sintaxis, se genera un contraejemplo o mensaje de error. Este trace se envía de vuelta al LLM como un nuevo prompt, orquestando una reparación reactiva iterativa sin intervención humana.

3.3 Sistemas Expertos Neuronales y Búsqueda de Pruebas (AlphaGeometry2 y NELLIE):

Pipeline: Uso de motores deductivos con estrategias backward chaining (ej. Prolog) acoplados al LLM. El modelo de lenguaje se utiliza como función heurística para proponer ramificaciones o generar construcciones auxiliares (ej. nuevos puntos en geometría).

Retroalimentación: El motor simbólico (DDAR en AlphaGeometry2) extrae deductivamente nuevas premisas a partir de los puntos generados por la red neuronal, hasta validar la prueba formal.

4. Análisis Crítico: Cuellos de Botella y Fragilidad del Sistema

4.1. Latencia y Cuellos de Botella Computacionales: Análisis del alto coste asociado a invocar solvers lógicos pesados en cada nodo de un árbol de búsqueda o planificación. Esto genera una latencia inaceptable para escalar estos modelos a aplicaciones en tiempo real o en la intemperie (in the wild).

4.2. Extrema Fragilidad de Traducción: Discusión sobre cómo las alucinaciones en la etapa inicial de conversión (del LLM a PDDL/FOL) generan representaciones sintácticamente inválidas o con predicados inventados. Una mala traducción inicial destruye por completo el flujo de inferencia simbólica subsecuente, haciendo que el sistema dependa excesivamente de prompts ultra-específicos.

5. Cuestiones Éticas, Sesgos y Retos Futuros

5.1. Ética y Propagación de Sesgos en Entornos Híbridos: La integración neurosimbólica introduce nuevas complejidades algorítmicas; las redes neuronales inyectan sesgos ocultos en los datos (sub-simbólicos), mientras que los marcos simbólicos dependen de reglas definidas por humanos que pueden estar pre-sesgadas y perpetuar desigualdades.

5.2. Responsabilidad (Accountability) y Transparencia: La necesidad imperativa de auditar los procesos de toma de decisiones en tareas de alto riesgo (medicina, derecho), aprovechando la explicabilidad teórica que proveen los árboles de prueba lógicos en los sistemas NeSy.

Bibliografía (puede ser ampliada)

- [1]
A. Patil and A. Jadon, “Advancing Reasoning in Large Language Models: Promising Methods and Approaches,” May 28, 2025, *arXiv*: arXiv:2502.03671. doi: [10.48550/arXiv.2502.03671](https://doi.org/10.48550/arXiv.2502.03671).
- [2]
S. K. Jha *et al.*, “Counterexample Guided Inductive Synthesis Using Large Language Models and Satisfiability Solving,” in *MILCOM 2023 - 2023 IEEE Military Communications Conference (MILCOM)*, Oct. 2023, pp. 944–949. doi: [10.1109/MILCOM58377.2023.10356332](https://doi.org/10.1109/MILCOM58377.2023.10356332).
- [3]
K. Hua, D. Wang, Y. Gu, and X. Ma, “DUPLEX: Agentic Dual-System Planning via LLM-Driven Information Extraction,” Mar. 25, 2026, *arXiv*: arXiv:2603.23909. doi: [10.48550/arXiv.2603.23909](https://doi.org/10.48550/arXiv.2603.23909).
- [4]
Y. Chervonyi *et al.*, “Gold-medalist Performance in Solving Olympiad Geometry with AlphaGeometry2,” Dec. 08, 2025, *arXiv*: arXiv:2502.03544. doi: [10.48550/arXiv.2502.03544](https://doi.org/10.48550/arXiv.2502.03544).
- [5]
M. Besta *et al.*, “Graph of thoughts: solving elaborate problems with large language models,” in *Proceedings of the Thirty-Eighth AAAI Conference on Artificial Intelligence and Thirty-Sixth Conference on Innovative Applications of Artificial Intelligence and Fourteenth Symposium on Educational Advances in Artificial Intelligence*, in AAAI’24/

IAAI'24/EAAI'24, vol. 38. AAAI Press, Feb. 2024, pp. 17682–17690. doi: [10.1609/aaai.v38i16.29720](https://doi.org/10.1609/aaai.v38i16.29720).

[6]

M. Fang *et al.*, “Large Language Models Are Neurosymbolic Reasoners,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 16, pp. 17985–17993, Mar. 2024, doi: [10.1609/aaai.v38i16.29754](https://doi.org/10.1609/aaai.v38i16.29754).

[7]

B. Liu *et al.*, *LLM+P: Empowering Large Language Models with Optimal Planning Proficiency*. 2023. doi: [10.48550/arXiv.2304.11477](https://doi.org/10.48550/arXiv.2304.11477).

[8]

L. Pan, A. Albalak, X. Wang, and W. Wang, “Logic-LM: Empowering Large Language Models with Symbolic Solvers for Faithful Logical Reasoning,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*, H. Bouamor, J. Pino, and K. Bali, Eds., Singapore: Association for Computational Linguistics, Dec. 2023, pp. 3806–3824. doi: [10.18653/v1/2023.findings-emnlp.248](https://doi.org/10.18653/v1/2023.findings-emnlp.248).

[9]

R. Riegel *et al.*, “Logical Neural Networks,” Jun. 23, 2020, *arXiv*: arXiv:2006.13155. doi: [10.48550/arXiv.2006.13155](https://doi.org/10.48550/arXiv.2006.13155).

[10]

D. Calanzone, S. Teso, and A. Vergari, “Logically Consistent Language Models via Neuro-Symbolic Integration,” Sep. 09, 2024, *arXiv*: arXiv:2409.13724. doi: [10.48550/arXiv.2409.13724](https://doi.org/10.48550/arXiv.2409.13724).

[11]

N. Weir, P. Clark, and B. V. Durme, “NELLIE: A Neuro-Symbolic Inference Engine for Grounded, Compositional, and Explainable Reasoning,” Aug. 12, 2024, *arXiv*: arXiv:2209.07662. doi: [10.48550/arXiv.2209.07662](https://doi.org/10.48550/arXiv.2209.07662).

[12]

B. P. Bhuyan, A. Ramdane-Cherif, R. Tomar, and T. P. Singh, “Neuro-symbolic artificial intelligence: a survey,” *Neural Comput & Applic*, vol. 36, no. 21, pp. 12809–12844, Jul. 2024, doi: [10.1007/s00521-024-09960-z](https://doi.org/10.1007/s00521-024-09960-z).

[13]

L. Gao *et al.*, “PAL: Program-aided Language Models,” Jan. 27, 2023, *arXiv*: arXiv:2211.10435. doi: [10.48550/arXiv.2211.10435](https://doi.org/10.48550/arXiv.2211.10435).

[14]

L. Luo, Y.-F. Li, G. Haffari, and S. Pan, “Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning,” presented at the The Twelfth International Conference on Learning Representations, Oct. 2023. Accessed: Apr. 11, 2026. [Online]. Available: <https://openreview.net/forum?id=ZGNWW7xZ6Q>

[15]

T. H. Trinh, Y. Wu, Q. V. Le, H. He, and T. Luong, “Solving olympiad geometry without human demonstrations,” *Nature*, vol. 625, no. 7995, pp. 476–482, Jan. 2024, doi: [10.1038/s41586-023-06747-5](https://doi.org/10.1038/s41586-023-06747-5).

[16]

W. Wang, Y. Yang, and F. Wu, “Towards Data-And Knowledge-Driven AI: A Survey on Neuro-Symbolic Computing,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 2, pp. 878–899, Feb. 2025, doi: [10.1109/TPAMI.2024.3483273](https://doi.org/10.1109/TPAMI.2024.3483273).